MOHAMED AYMANE BADIA

Data Science & Machine Learning | Élève ingénieur en dernière année, IA & Data Science (EMSI Marrakech)

Marrakech, Maroc | +212 635 546 955 | badiamohamedaymane@gmail.com | Portfolio : aymane-portfolio-lime.vercel.app
LinkedIn : linkedin.com/in/mohamed-aymane-badia-40a9712a1 | GitHub : github.com/BADIAMOHAMEDAYMANE

PROFIL PROFESSIONNEL

Élève ingénieur en dernière année d'Intelligence Artificielle et Data Science (EMSI Marrakech). Stage PFA chez Lama Healthcare (États-Unis) sur une plateforme d'accréditation de praticiens de santé : responsable front-end (Next.js, TypeScript) et expérimentations d'extraction automatique de documents (fine-tuning LoRA d'un LLM, sortie JSON structurée). Projets personnels en Deep Learning, NLP et OCR (PyTorch, Hugging Face), avec des résultats mesurés. Je recherche un stage de fin d'études (PFE) de 6 mois en Data Science / Intelligence Artificielle, à partir de février 2027.

EXPÉRIENCE PROFESSIONNELLE

Stagiaire PFA – Développement Front-end & IA | Juillet 2026 – Septembre 2026
Lama Healthcare (plateforme Practice One), Las Vegas, Nevada, États-Unis

- Refonte, en équipe de trois, d'une plateforme SaaS d'accréditation (*credentialing*) de praticiens de santé américains, dans un périmètre HIPAA.
- Responsable front-end : design system et composants réutilisables ; livraison du tableau de bord, des dossiers professionnels, du workflow d'accréditation, des alertes, du journal d'audit et d'une page publique de dépôt de documents.
- Extraction de documents : comparaison de modèles vision-langage, puis fine-tuning LoRA de Qwen3-1.7B sur GPU T4 : 100 % de JSON valides (60/60) et 87 % de champs corrects (124/143) sur le jeu public CORD, pic de 3,3 Go de VRAM.
- Sécurité des données : contribution au contrôle d'accès par rôles (RBAC), au masquage des données et à la traçabilité des accès ; 6 rôles sur 6 validés par des tests d'accès.
- **Environnement technique :** Next.js, TypeScript, Tailwind CSS, Supabase, PostgreSQL, Zod, Hugging Face Transformers, PEFT/LoRA, TRL, Git ; équipe anglophone.

COMPÉTENCES TECHNIQUES

Langages : Python, TypeScript, JavaScript, SQL, Java, C#, PHP
Machine Learning : Scikit-learn, Pandas, NumPy, TF-IDF, KMeans, Random Forest, XGBoost/LightGBM, évaluation de modèles
Deep Learning, NLP et OCR : PyTorch, TensorFlow/Keras, CNN, Hugging Face Transformers, PEFT/LoRA, TRL, spaCy, NLTK, Tesseract
Données : PostgreSQL, Supabase, MySQL, Matplotlib, Plotly
Web et API : Next.js, React, Tailwind CSS, Flask, ASP.NET Core MVC, EF Core, Laravel, API REST, JWT
Outils et pratiques : Git, Docker, Streamlit, Google Colab, Kaggle, Postman, pytest, architectures MVC / N-Tier

PROJETS

Invoice Intelligence AI – extraction de factures par OCR + LLM | Python, Transformers, PEFT/LoRA, Tesseract, PyMuPDF, Pydantic, pytest, Streamlit

- Pipeline photo/PDF → OCR Tesseract → Qwen2.5-0.5B-Instruct fine-tuné en LoRA (8,8 M de paramètres entraînables sur 503 M) → JSON structuré → réparation arithmétique et validation Pydantic → démo Streamlit.
- Exactitude par champ de 0,99 contre 0,54 pour le modèle de base et 0,53 pour une méthode à base de règles (jeu de test synthétique) ; limites de généralisation sur de vrais tickets mesurées et documentées.

TrendRadar – détection de tendances sur Reddit | Python, spaCy, NLTK, Scikit-learn, XGBoost/LightGBM, Plotly, Streamlit

- Application de bout en bout (~3 300 lignes de Python, 5 modules) : collecte Reddit avec cache Parquet, NLP français/anglais (détection de langue, lemmatisation, entités nommées), vectorisation TF-IDF.
- Regroupement des sujets par KMeans et classification Random Forest, détection de pics par fenêtres glissantes, prédiction de viralité par gradient boosting, tableau de bord interactif.

Classification d'images CIFAR-10 déployée | PyTorch, CUDA (GPU T4), Streamlit, Docker Compose

- CNN de 3 blocs (Conv2D, BatchNorm, Dropout, ~500 k paramètres) entraîné avec Adam et StepLR : environ 78 % d'accuracy sur le jeu de test.
- Application Streamlit déployée en ligne et conteneurisée (Docker Compose), avec filtre des images hors domaine (MobileNetV2) et rejet des prédictions peu sûres (seuils de confiance et d'entropie).

FORMATION ET CERTIFICATIONS

Diplôme d'ingénieur (MEng) en Intelligence Artificielle et Data Science | 2022 – 2027
EMSI – École Marocaine des Sciences de l'Ingénieur, Marrakech

- Cycle ingénieur de 5 ans (équivalent Master of Science). Cours principaux : Machine Learning, Deep Learning, NLP, bases de données, génie logiciel.
- **Certification :** Software Design & Project Management (Coursera)

LANGUES

Arabe : langue maternelle | Français : bilingue | Anglais : intermédiaire avancé (B2)